

Análise de Complexidade

Função de Complexidade

- Descreve o “custo” de executar um algoritmo dado o tamanho da entrada (o tal do “n”)
- Geralmente remete ao “Pior Caso”, mas também pode ser referente ao “Caso Médio”
 - “Melhor Caso” é válido, mas raramente útil
- Todo algoritmo possui um “custo”
 - Tempo de processamento
 - Alocação de memória
 - Operações lentas (ler arquivo)
 - Tempo online no AWS
- Abstrai muito dos detalhes de implementação

O que se presume?

- Analisando o tempo de execução
 - Todas operações tem o mesmo custo
 - Não há interferência do Sistema Operacional
 - Não acontecem erros
- Analisando a memória
 - O sistema nunca fica sem espaço
 - Não inclui memória do sistema

Exemplo: Busca Maior elemento

A: Array // tamanho = n

func find_max(A):

max = A[0] // c1

for elemento in A: // roda n vezes

if elemento > max: // c2

max = elemento // c3

return max // c4

$$F(n) = c1 + c4 + n*(c2 + c3) = c5 + c6*n \approx n$$

Detalhe Importante: Tamanho

- Complexidade é sempre em termos relativos ao **tamanho** da entrada
- Mas não pode se presumir o formato dessa entrada
 - Caso seja feito, sua complexidade vai se aplicar a uma versão “restrita” do problema
- O tamanho pode ser separado dependendo da entrada
 - Exemplo: Algoritmo recebe dois arrays diferentes como entrada

Exemplo: Busca Por Elemento (Sequencial)

A: Array, buscado: Int

```
func find_normal(A, buscado):  
    size = A.size()  
    for indice in 0..size: // máximo n vezes  
        elemento = A[indice] // cada operação  
        if elemento == buscado: // executa apenas 1 vez  
            return indice
```

Complexidade (pior caso): $F(n) = n$

Mas e o caso médio?

A: Array, buscado: Int

```
func find_normal(A, buscado):  
    size = A.size()  
    for indice in 0..size:  
        elemento = A[indice]  
        if elemento == buscado:  
            return indice
```

- Supondo que o elemento sempre está no array
- E que ele tem probabilidade igual de estar em qualquer posição
- A complexidade do caso médio é $F(n) = (n+1)/2$


Análise Assintótica

- Análise de funções para “valores arbitrariamente grandes”
 - Semelhante ao estudo de limites em cálculo
- Separa funções em conjuntos chamados “Ordens de Complexidade”
- Pode ser simplificada focando nos fatores “dominantes”
- Facilita comparação de algoritmos

Notação de Ordens de Complexidade

- Define uma classe de funções com base em uma função “limite”
- Existem 3 tipos principais:
 - O (“ó grande”) e Ω (“Omega grande”) são opostos
 - Θ (“téta grande”) é a união dos dois
- Para dizer que uma função f pertence a “ó grande” de outra g :
 - $f(n) = O(g(n))$

Exemplo “Intuitivo”




- Nesse exemplo, a partir de um certo ponto:
- F nunca vai superar G
- H nunca vai superar F
- H nunca vai superar G

Definição Formal

- Útil pra provar complexidades na prova!
- Dadas duas funções $f(n)$ e $g(n)$, podemos dizer que $f(n) = O(g(n))$
- Se
 - A partir de algum n' arbitrário, exista uma constante C tal que:
 - $f(n) < C \cdot g(n)$
 - Se $n > n'$
- O mesmo vale pra Ω , trocando apenas a comparação para “>”
- $f(n) = \Theta(g(n))$ se e somente se f for $O(g(n))$ e $\Omega(g(n))$

Divisão em Classes

- Ordens de complexidade dividem as funções em classes
- Existe uma “hierarquia de funções” mais comuns
 - As “piores” são as exponenciais
 - As “melhores” são as logarítmicas



Na Prática

- A grande maioria dos algoritmos usáveis são “Polinomiais”
 - Da ordem $O(n^x)$ onde x é um número positivo
 - O termo polinomial de maior expoente “domina” os menores
 - $F(n) = n + 100000 \cdot n^2 + 0.00001 \cdot n^3 = \Theta(n^3)$
- Funções logarítmicas são mais “lentas” que qualquer polinômio
- Exponenciais são raras em algoritmos usáveis
 - Rapidamente se tornam “intratáveis”

Na prática: Busca Maior

A: Array // tamanho = n

func find_max(A):

max = A[0] // c1

for elemento in A: // roda n vezes

if elemento > max: // c2

max = elemento // c3

return max // c4

$$F(n) = c1 + c4 + n*(c2 + c3) = c5 + c6*n \approx n = O(n)$$

Na Prática: Caso Médio da Busca Sequencial

A: Array, buscado: Int

```
func find_normal(A, buscado):  
    size = A.size()  
    for indice in 0..size:  
        elemento = A[indice]  
        if elemento == buscado:  
            return indice
```

- A complexidade é
 $F(n) = (n+1)/2$
- $(n+1)/2 = \Theta(n)$
- Portanto a ordem de complexidade do caso médio é $\Theta(n)$

Um exemplo mais complexo: InsertionSort

A: Array

func sort(A):

for i in 0..(A.size-1): // executa de 0 até n-1

// função find_max vista anteriormente: $\Theta(n)$

max = find_max(A[i:]) // maior elemento a partir de i

troca(A[max], A[i]) // coloca maior elemento em i

Executa n vezes uma função com complexidade $\Theta(n)$

Complexidade: **$f(n) = \Theta(n^2)$**

Foi isso

Caso dê tempo: Teorema Mestre

- Teorema usado pra funções recursivas
 - Particularmente as do tipo “dividir para conquistar”
- Simplifica bastante o processo de análise de funções assim
- Possui 3 casos onde se aplica

Exemplo: Busca Binária

```
A: Array, buscado: Int // A é ordenado
func find_binario(A, buscado, comeco, fim):
    meio = (comeco+fim)/2
    if buscado == A[meio]:
        return meio
    elif buscado < A[meio]:
        return comeco + find_binario(A, buscado, meio, fim)
    else:
        return meio + find_binario(A, buscado, meio, fim)
```

Os casos do teorema mestre

- Seja **a** o número de vezes que uma função se chama
- Seja **b** o fator pelo qual a entrada é dividida
- Seja $f(n)$ a complexidade não-recursiva de uma chamada
- O teorema mestre avalia a expressão de complexidade da forma

$$T(n) = aT(n/b) + f(n)$$

$$T(0) = 1$$

Os 3 casos

- Sempre compara a função não-recursiva $f(n)$ com o custo recursivo
 - Custo recursivo é dado na forma n^c , sendo $c = \log_b(a)$
- Uma versão simplificada:
 - Se $f(n) < n^c$, $T(n) = \Theta(n^c)$
 - Se $f(n) = n^c$, $T(n) = \Theta(f(n) \cdot \log(n))$
 - Se $f(n) > n^c$, $T(n) = \Theta(f(n))$
- Mas existem detalhes importantes!